Cadenas de Markov

De una disputa filosófica rusa al corazón de Google, la IA y la predicción de texto

Dr. Jorge Muro Arbulú

31 de marzo de 2026

Resumen

Las cadenas de Markov son uno de los conceptos matemáticos más influyentes de la historia moderna, aunque su nombre rara vez aparezca en las conversaciones cotidianas sobre tecnología. Nacidas en 1905 de una acalorada disputa entre un matemático ateo y un estadístico profundamente religioso en la Rusia imperial, estas estructuras probabilísticas constituyen el fundamento teórico del algoritmo PageRank de Google, que determina qué páginas web aparecen primero en los resultados de búsqueda modelizando a un navegante que salta de enlace en enlace de forma aleatoria, del Método de Monte Carlo utilizado en el Proyecto Manhattan para simular el comportamiento de los neutrones en una bomba nuclear, y de los modelos de lenguaje a gran escala que hoy sostienen herramientas como ChatGPT, Claude o Gemini. Este artículo traza el arco histórico de esa idea desde su origen polémico hasta sus aplicaciones más actuales, explicando con rigor, pero sin tecnicismos innecesarios qué son las cadenas de Markov, por qué son tan poderosas y qué límites tienen.

Palabras clave: cadenas de Markov, probabilidad, PageRank, modelos de lenguaje, propiedad de falta de memoria, Método de Monte Carlo.

I. Introducción: cuando las matemáticas y la teología se enfrentaron

Hay ideas que cambian el mundo sin que nadie lo advierta en el momento. En 1905, en San Petersburgo, dos matemáticos rusos protagonizaron una disputa que parecía filosófica y resultó ser fundacional. El objeto del debate era aparentemente abstracto: si la independencia estadística de los eventos era o no una condición necesaria para que operara la probabilidad. Detrás de esa pregunta técnica se escondían implicaciones que sus protagonistas consideraban tan profundas como la existencia del libre albedrío.

Ciento veinte años después, esa misma disputa está en el corazón del algoritmo que decide qué página web aparece primera en Google, del método que los físicos del Proyecto Manhattan utilizaron para simular el comportamiento de los neutrones en una bomba nuclear, y de la tecnología que permite a un modelo de lenguaje predecir cuál es la palabra más probable para completar una oración. Las cadenas de Markov no son solo una herramienta matemática; son una forma de entender cómo el presente contiene suficiente información para anticipar el futuro, sin necesidad de cargar con todo el peso del pasado.

II. El origen: una disputa entre la fe y el rigor (1905)

2.1 Pavel Necrasov: el zar de la probabilidad

Pavel Necrasov era conocido en los círculos académicos rusos como el "zar de la probabilidad". Profundamente religioso, encontraba en las matemáticas una confirmación de sus convicciones espirituales. Su argumento central era elegante, aunque cuestionable: dado que las estadísticas sociales, como las tasas de matrimonio, los índices de criminalidad o los registros de nacimiento, convergían año tras año a valores promedio predecibles, esa convergencia demostraba que las decisiones individuales eran estadísticamente independientes entre sí. Y si las decisiones eran independientes, sostenía Necrasov, era porque cada individuo tomaba sus decisiones de forma autónoma, libre de la influencia de las decisiones ajenas. Las matemáticas, concluía, probaban el libre albedrío y, con él, la existencia de la voluntad divina. (Sethna, 2006)

2.2 Andrey Markov: el desafío del ateo riguroso

Andrey Markov era ateo y tenía una concepción estricta del rigor matemático. Le resultaba intolerable que un argumento teológico se sostuviera sobre lo que consideraba una confusión lógica. El error de Necrasov, según Markov, era asumir que la convergencia a un promedio requería necesariamente independencia entre los eventos. Esa suposición no estaba demostrada. Y si se podía demostrar lo contrario, es decir, que eventos dependientes también podían converger a una distribución estable, el argumento de Necrasov se derrumbaba. (Hayes, 2013)

Markov no necesitaba refutar el libre albedrío filosóficamente. Solo necesitaba construir un ejemplo matemático que funcionara. Y lo hizo con una novela en verso.



Figura 1

El origen de las cadenas de Markov: la disputa ideológica de 1905.

Nota. Representación esquemática de los argumentos centrales de Pavel Necrasov y Andrey Markov en la disputa que dio origen a las cadenas de Markov. Elaboración propia a partir de Sethna (2006) y Hayes (2013).

III. La Ley de los Grandes Números y el error de Necrasov

Para entender por qué la disputa entre Necrasov y Markov importaba matemáticamente, conviene conocer la ley que estaba en el centro del debate. La Ley de los Grandes Números, formulada por Jakob Bernoulli en el siglo XVII y refinada por figuras como Poisson y Chebyshev, establece que a medida que aumenta el número de repeticiones de un experimento aleatorio, el promedio de los resultados se acerca cada vez más al valor esperado teórico. Lanzar una moneda diez veces puede dar ocho caras; lanzarla diez millones de veces producirá un resultado cercano al 50% con una certeza prácticamente absoluta. (Feller, 1968)

La versión clásica de esta ley requería que los eventos fueran independientes entre sí, es decir que cada lanzamiento de moneda no debía verse afectado por los lanzamientos anteriores. Necrasov construyó sobre esa premisa su argumento teológico, sosteniendo que, si las estadísticas sociales convergían a un promedio, era porque las decisiones individuales eran independientes entre sí, es decir, libres. Pero independencia y libertad no son la misma cosa, y mucho menos en matemáticas y fue entonces que Markov identificó el error. La convergencia a una distribución estable no requería independencia, sino algo más débil y más general, que la dependencia entre eventos tuviera una estructura específica y acotada. Demostrar eso era suficiente para derribar el argumento de Necrasov. Y para demostrarlo, Markov recurrió a un poema.

IV. El experimento con “Eugenio Oneguin”: la primera cadena de Markov

Para refutar a Necrasov, Markov recurrió a un método empírico. Tomó el texto del poema épico de Alexander Pushkin, “Eugenio Oneguin”, y analizó manualmente 20,000 letras consecutivas. Su objetivo era demostrar que la aparición de una vocal o una consonante dependía de la letra inmediatamente anterior, es decir, que los eventos no eran independientes, y que aun así la proporción de vocales y consonantes convergía a un valor estable (Markov, 1913, citado en Hayes, 2013).

Los resultados fueron precisos. La probabilidad de que una vocal fuera seguida por una consonante era del 66,3%, y la de que una consonante fuera seguida por una vocal era del 43,2%. Estos números no eran iguales, lo que confirmaba la dependencia entre eventos consecutivos. Sin embargo, independientemente del punto de partida, la proporción de vocales en el texto convergía invariablemente al mismo valor de aproximadamente el 43%. La historia previa de la secuencia no importaba para predecir la distribución a largo plazo. Solo importaba el estado actual.

Markov había construido lo que hoy llamamos una cadena de Markov, es decir un sistema en el que la probabilidad de cada estado futuro depende únicamente del estado presente, y no de los estados anteriores. Esta propiedad, conocida como la propiedad de Markov o propiedad

de falta de memoria, es lo que hace a estas cadenas simultáneamente simples de analizar y extraordinariamente potentes en la práctica.

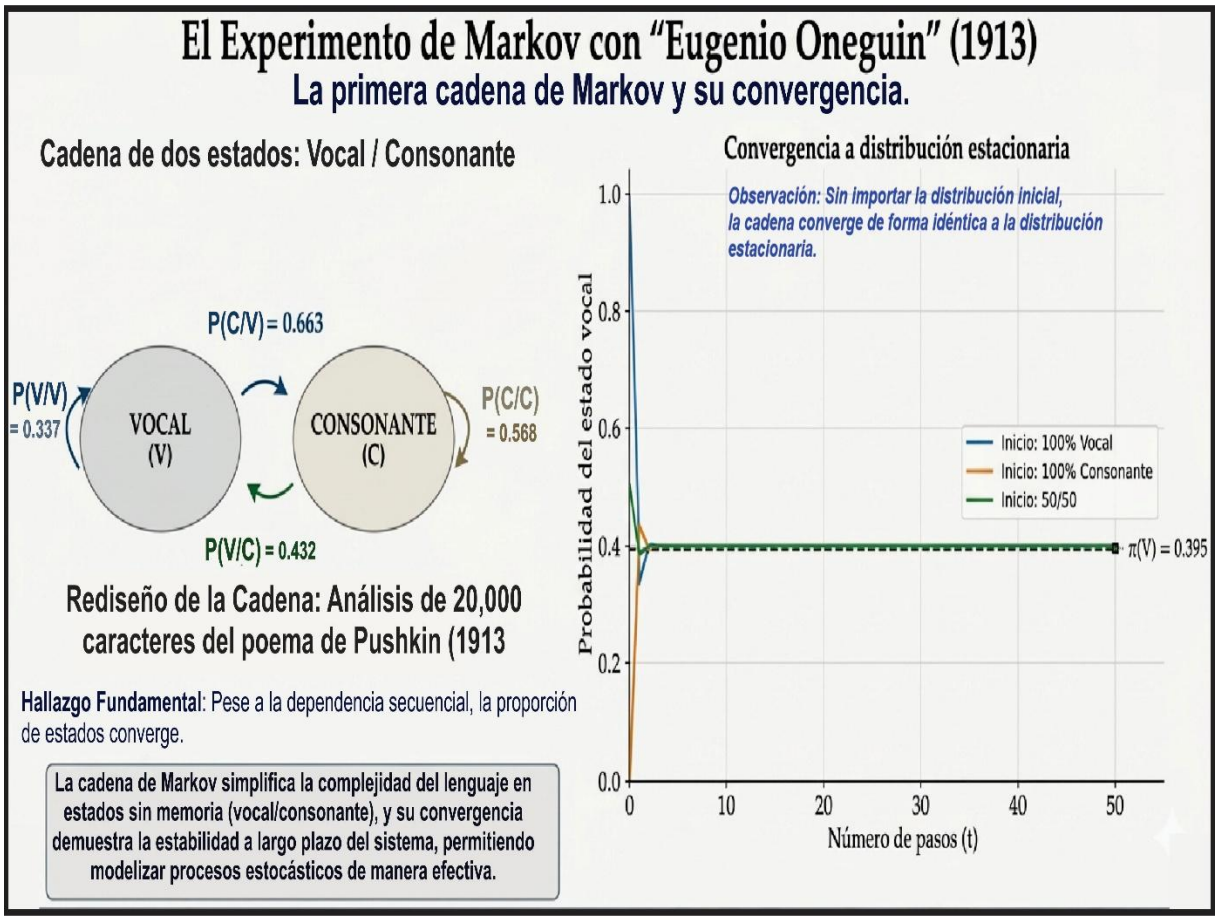


Figura 2

El experimento de Markov con "Eugenio Oneguin" (1913).

Nota. Panel izquierdo: diagrama de la cadena de dos estados (Vocal/Consonante) con las probabilidades de transición calculadas por Markov a partir de 20.000 letras del poema de Pushkin. Panel derecho: convergencia a la distribución estacionaria desde distintos estados iniciales, demostrando que la historia previa no afecta el resultado a largo plazo. Elaboración propia a partir de Markov (1913, citado en Hayes, 2013).

Ese campo matemático completamente nuevo tardó menos de cuatro décadas en encontrar una de sus aplicaciones más urgentes y.

V. La era nuclear: el Método de Monte Carlo, la ENIAC y los neutrones

Durante el Proyecto Manhattan, uno de los problemas más urgentes era predecir el comportamiento de los neutrones en una reacción de fisión nuclear. Cuando un neutrón colisiona con un núcleo de uranio o plutonio, el resultado depende de esa colisión específica dado que el neutrón puede ser absorbido, puede provocar fisión liberando más neutrones, o puede dispersarse en una dirección determinada por probabilidades cuánticas. Para saber si se produciría una reacción en cadena sostenida y bajo qué condiciones, era necesario seguir

la trayectoria de millones de neutrones a través de cientos de colisiones sucesivas. Ninguna fórmula analítica resolvía el problema. El sistema era perfectamente markoviano: el estado futuro de cada neutrón dependía únicamente de su estado tras el último choque, y no de toda su historia previa.

Enrico Fermi ya usaba desde principios de los años cuarenta estimaciones estadísticas intuitivas para calcular secciones eficaces de colisión neutrónica. Von Neumann, que llegó a Los Álamos en 1943 como consultor matemático del Proyecto Manhattan, formalizó esa intuición en un método sistemático de simulación estocástica, es decir, basada en procesos aleatorios controlados en lugar de ecuaciones deterministas. Para ejecutar esos cálculos a la escala que el problema exigía, von Neumann[1] fue uno de los principales impulsores de la construcción de la ENIAC, acrónimo de *Electronic Numerical Integrator And Computer* (Integrador Numérico Electrónico y Computador). Construida en la Universidad de Pensilvania y completada en febrero de 1946. Cabe precisar que, en paralelo, el gobierno británico había construido en secreto el Colossus en Bletchley Park desde 1943, una máquina electrónica programable dedicada exclusivamente al descifrado de los códigos alemanes Lorenz. Pero su existencia fue clasificada durante treinta años, de modo que no tuvo ningún impacto sobre el desarrollo del cómputo científico de la época. La ENIAC, en ese sentido, fue la primera computadora electrónica de propósito general conocida y disponible para la comunidad científica, y su primera aplicación de envergadura fueron los cálculos de von Neumann para el diseño de la bomba de hidrógeno (Britannica, 2026; Eckhardt, 1987).

Fue Stanislaw Ulam quien, convaleciente de una enfermedad en Los Álamos en 1946, quien formalizó el principio general del método a partir de una reflexión sobre el solitario: si calcular analíticamente la probabilidad de ganar una partida era combinatoriamente intratable, bastaba con simularla miles de veces y observar la frecuencia de victorias. La generalización era poderosa pues cualquier problema de probabilidad intratable analíticamente podía aproximarse mediante simulación masiva de sus procesos aleatorios subyacentes. Ulam lo expuso a von Neumann, quien reconoció de inmediato que era exactamente lo que ya hacían con los neutrones, pero ahora como principio explícito y general. El nombre para este método fue propuesto en Los Álamos, en referencia al casino de Mónaco, subrayando el azar como motor del método. (Metropolis y Ulam, 1949).

El Método Monte Carlo y las cadenas de Markov no son la misma cosa, pero se necesitan mutuamente para resolver ciertos problemas. Una cadena de Markov describe la arquitectura del sistema con todos los estados posibles y las probabilidades de transición entre ellos. Monte Carlo es la técnica de ejecución ya que en lugar de calcular analíticamente la distribución estacionaria, se simulan miles o millones de trayectorias y se observa hacia dónde

[1] John von Neumann (1903-1957) es considerado uno de los matemáticos más prolíficos del siglo XX. Además de su trabajo en el Proyecto Manhattan y en el diseño de la arquitectura de los computadores modernos, es el fundador de la teoría de juegos moderna, disciplina que estudia la toma de decisiones estratégicas en situaciones de interdependencia. Su obra fundamental, *Theory of Games and Economic Behavior*, publicada en 1944 junto al economista Oskar Morgenstern, sentó las bases de la economía matemática contemporánea y de campos tan diversos como la biología evolutiva, la ciencia política y la inteligencia artificial. El mismo año en que formalizaba el método de Monte Carlo para calcular neutrones, terminaba de escribir el libro que cambiaría la teoría económica.

converge el sistema. En el caso neutrónico, la cadena de Markov describía cómo cada choque determinaba el estado siguiente de la partícula. Monte Carlo permitía simular millones de esas trayectorias para estimar si se alcanzaría masa crítica. Sin la estructura markoviana, no habría forma de saber qué simular. Sin Monte Carlo, esa estructura sería matemáticamente inabordable[2].

La disputa filosófica de 1905 había encontrado, cuarenta años después, una de las aplicaciones más determinantes de la historia contemporánea. Markov quería refutar a un estadístico religioso. Lo que construyó para hacerlo terminó siendo la herramienta matemática que permitió calcular la masa crítica de una bomba nuclear. Las dos detonaciones sobre Japón en agosto de 1945 cerraron la Segunda Guerra Mundial. Lo que siguió fue medio siglo de Guerra Fría en el que las dos superpotencias, URSS y EE. UU., acumularon arsenales capaces de destruir la civilización varias veces, pero nunca los usaron. Los estrategas denominaron ese equilibrio disuasión mutua asegurada, conocida por su acrónimo en inglés MAD, cuya lógica central es que ningún actor racional inicia un conflicto nuclear si la represalia garantiza su propia destrucción.

Si ese equilibrio evitó o simplemente postergó un conflicto de mayor escala es una pregunta que los historiadores aún no han resuelto. Lo que no se debate es que la estructura del orden internacional de la segunda mitad del siglo XX fue configurada, en parte, por una cadena de cálculos matemáticos que comenzó con las letras de un poema ruso.

VI. La revolución de Google: PageRank como cadena de Markov

6.1 El problema de los motores de búsqueda en los años noventa

En los primeros años del World Wide Web, los motores de búsqueda como AltaVista o Yahoo utilizaban un método simple para determinar la relevancia de una página: contar cuántas veces aparecía el término buscado en su contenido. El sistema era fácilmente manipulable. Bastaba con repetir una palabra clave cientos de veces en texto invisible para que una página de escasa calidad apareciera en los primeros resultados. La web crecía a una velocidad exponencial, y la calidad de las búsquedas se deterioraba en paralelo. (Brin y Page, 1998)

6.2 El navegante aleatorio y el PageRank

En 1998, Larry Page y Sergey Brin, entonces estudiantes de doctorado en Stanford, publicaron el artículo que describía el algoritmo PageRank. Su intuición central era modelizar el comportamiento de un “navegante aleatorio”: un usuario hipotético que comienza en una página web cualquiera y sigue enlaces de forma aleatoria, saltando de página en página sin

[2] El autor utiliza el software Analytica, desarrollado por Lumina Decision Systems, para la construcción y simulación de modelos probabilísticos basados en cadenas de Markov y el Método Monte Carlo. Analytica implementa nativamente redes de influencia con muestreo Monte Carlo, permitiendo explorar distribuciones de resultados en lugar de valores puntuales. Véase Muro Arbulú, J. E. (2023). Toma de Decisiones Bajo Incertidumbre: Enfoque Estadístico. https://www.jorgemuro.net/es/publicaciones

ningún criterio particular. La pregunta era: si ese navegante continuara navegando indefinidamente, ¿qué proporción del tiempo pasaría en cada página? (Page et al., 1999)

La respuesta a esa pregunta es exactamente lo que calcula una cadena de Markov: la distribución estacionaria del sistema. Una página recibe un PageRank alto si muchas otras páginas enlazan a ella, especialmente si esas otras páginas son a su vez muy enlazadas. El algoritmo no mide directamente la calidad del contenido, sino la estructura de confianza de la red de páginas. Un enlace es un voto, pero el peso de ese voto depende de la autoridad de quien vota.

Formalmente, el PageRank de una página A se define como la suma de los PageRanks de todas las páginas que enlazan a A, dividida cada uno por el número de enlaces salientes de esa página. El proceso se calcula de forma iterativa hasta que los valores convergen, lo que ocurre porque la cadena de Markov subyacente tiene una distribución estacionaria única, exactamente lo que Markov demostró con las letras del poema de Pushkin noventa años antes.

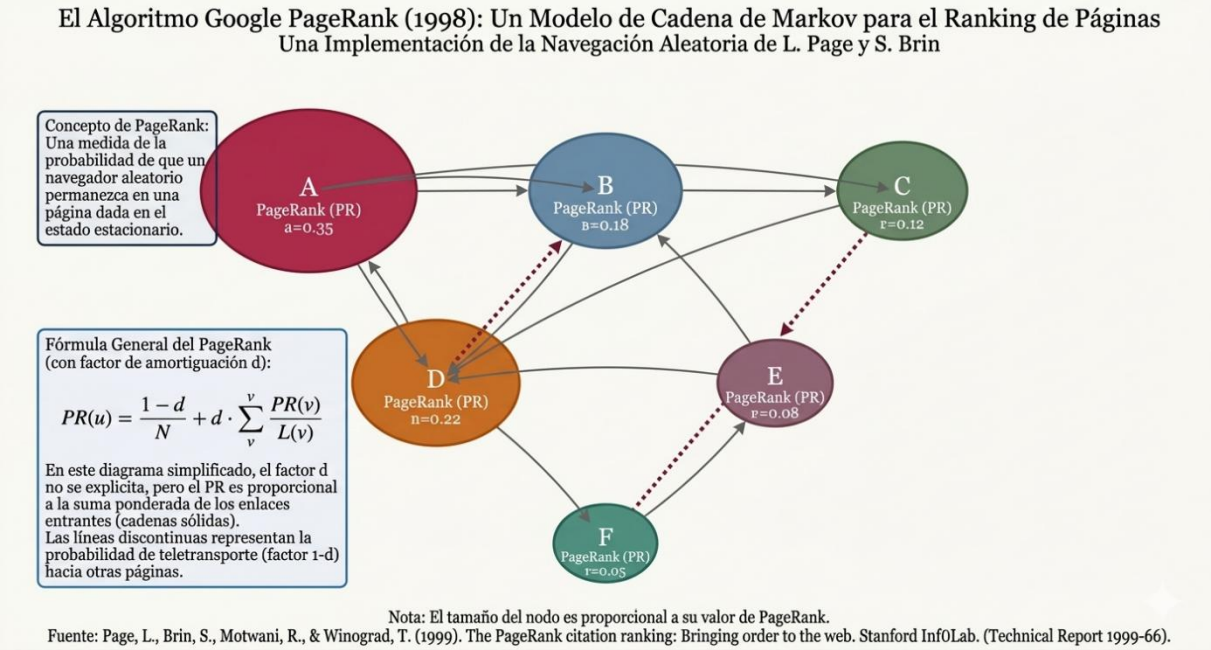


Figura 3

Google PageRank: la web como cadena de Markov (1998).

Nota. Diagrama de una red simplificada de páginas web con sus PageRanks estimados (tamaño del nodo proporcional al rango). Las flechas representan enlaces entre páginas y el grosor es proporcional al peso de la transición. La ruta punteada roja ilustra el recorrido de un navegante aleatorio. Elaboración propia a partir de Page et al. (1999).

VII. De Shannon a los modelos de lenguaje: predicción de texto

7.1 Claude Shannon y la entropía del lenguaje

En 1948, Claude Shannon publicó "*A Mathematical Theory of Communication*", el artículo fundacional de la teoría de la información. Entre sus experimentos más reveladores estaba el uso de n-gramas, es decir, secuencias de n palabras consecutivas, para modelizar estadísticamente el lenguaje. Shannon demostró que si se conoce la probabilidad de que una palabra suceda a las palabras anteriores en un texto, es posible generar texto artificial que parece plausible, aunque carece de significado real (Shannon, 1948).

El experimento de Shannon era, en esencia, una cadena de Markov aplicada al lenguaje en el que la palabra siguiente depende estadísticamente de las palabras anteriores. Cuantas más palabras previas se consideraran en el cálculo (lo que los lingüistas computacionales denominan el "orden" de la cadena), más coherente resultaba el texto generado. Pero ampliar el orden implicaba una explosión combinatoria de estados posibles que los computadores de la época no podían gestionar.

7.2 El mecanismo de atención y los LLM modernos

Los modelos de lenguaje modernos, como los que sustentan Gmail, ChatGPT o Claude, resuelven ese problema mediante una arquitectura introducida en 2017 por investigadores de Google Brain en el artículo "*Attention is all you need*". (Vaswani et al., 2017) El mecanismo de atención permite al modelo considerar simultáneamente todas las palabras del contexto disponible, ponderando cuánta "atención" debe prestar a cada una para predecir la siguiente. Esto equivale a una cadena de Markov de orden muy elevado, pero implementada de forma computacionalmente eficiente mediante álgebra matricial.

La diferencia práctica es significativa. Una cadena de Markov de primer orden para el lenguaje pregunta: dado que la última palabra fue "banco", ¿cuál es la palabra más probable a continuación? No puede distinguir si "banco" se refiere a una entidad financiera o a un asiento en un parque. El mecanismo de atención puede mirar decenas o cientos de palabras atrás y detectar que el contexto habla de "ahorro" y "préstamo", resolviendo la ambigüedad con precisión. Es el mismo principio markoviano, pero con una memoria de contexto considerablemente más larga y flexible.

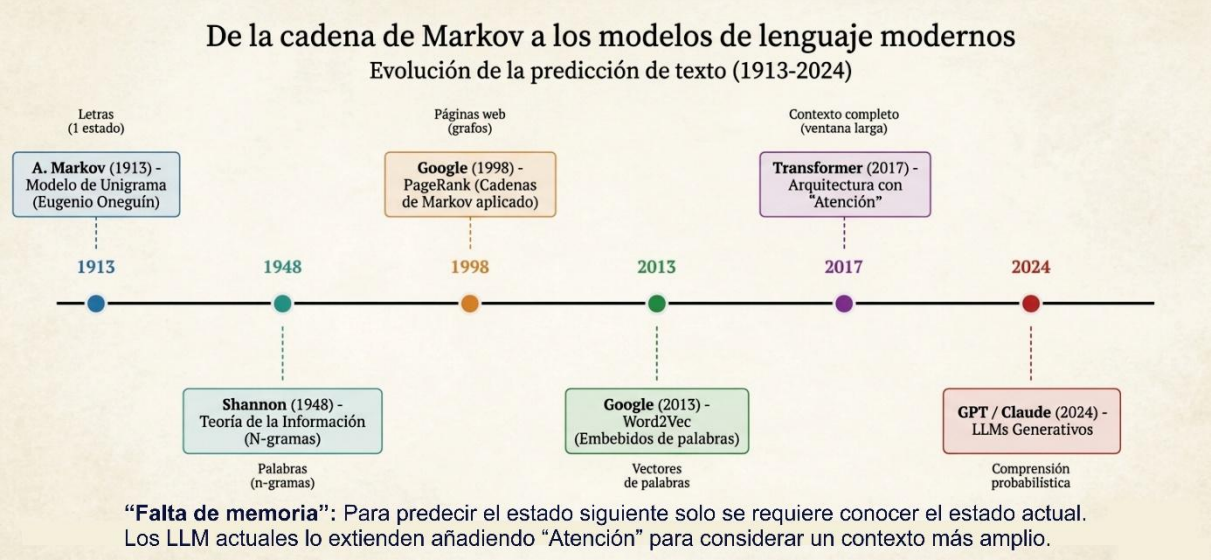


Figura 4

De la cadena de Markov a los modelos de lenguaje modernos (1913-2024).

Nota. Línea de tiempo de la evolución de la predicción de texto desde el experimento de Markov con Pushkin hasta los grandes modelos de lenguaje actuales. Cada hito amplió el "orden" efectivo de la cadena o la eficiencia de su cálculo. Elaboración propia.

VIII. La propiedad de falta de memoria: la clave de la potencia

Lo que hace a las cadenas de Markov tan poderosas es también lo que las limita, la falta de memoria, conocida formalmente como propiedad de Markov. Establece que la probabilidad del estado futuro del sistema, dado el presente, es independiente de todos los estados pasados. En términos más sencillos, para predecir adónde va el sistema basta con saber dónde está ahora.

Esta propiedad simplifica enormemente el análisis de sistemas complejos. En lugar de mantener un registro completo de toda la historia del sistema, basta con conocer su estado actual. Esa economía de información es lo que permitió a Markov analizar un poema con lápiz y papel, a von Neumann simular neutrones con los computadores primitivos de los años cuarenta, y a Google calcular el PageRank de miles de millones de páginas web con una eficiencia razonable.

La limitación es la otra cara de la misma moneda, hay sistemas en los que el pasado importa genuinamente, donde la historia no puede ignorarse sin perder información predictiva esencial. Los modelos de lenguaje modernos reconocen implícitamente esta limitación cuando amplían su ventana de contexto, es decir, el número de tokens, las unidades mínimas de texto en que el modelo divide el lenguaje, que pueden ser una palabra completa, una sílaba o un signo de puntuación, que el modelo puede considerar simultáneamente. Esa ventana pasó de los 512 tokens del Transformer original de 2017 al millón de tokens de algunos modelos actuales. La propiedad de Markov no se abandona; se extiende para que el estado presente incluya un fragmento de historia suficientemente largo (Vaswani et al., 2017).

IX. Dato curioso: cuántas veces hay que barajar un mazo de cartas

En 1992, los matemáticos Dave Bayer y Persi Diaconis publicaron un resultado sorprendente sobre el barajado de cartas. Utilizando cadenas de Markov para modelizar el proceso de mezcla de un mazo de 52 cartas mediante el método de rifle (el barajado intercalado que utilizan los crupieres), demostraron que se necesitan exactamente 7 barajadas para que el mazo alcance un nivel de aleatoriedad estadísticamente indistinguible de la mezcla perfecta (Bayer y Diaconis, 1992).

Con seis barajadas, el mazo aún contiene patrones detectables de su ordenamiento original. Con ocho, el nivel de aleatoriedad adicional es marginal. El resultado es no intuitivo porque la percepción humana de la aleatoriedad es notoriamente mala pues la mayoría de las personas considera que dos o tres barajadas son suficientes. El contraste con el barajado desordenado sobre la mesa, que requiere más de 2,000 repeticiones para alcanzar el mismo nivel de aleatoriedad, ilustra cuán eficiente es el método de rifle desde el punto de vista de la teoría de la información.

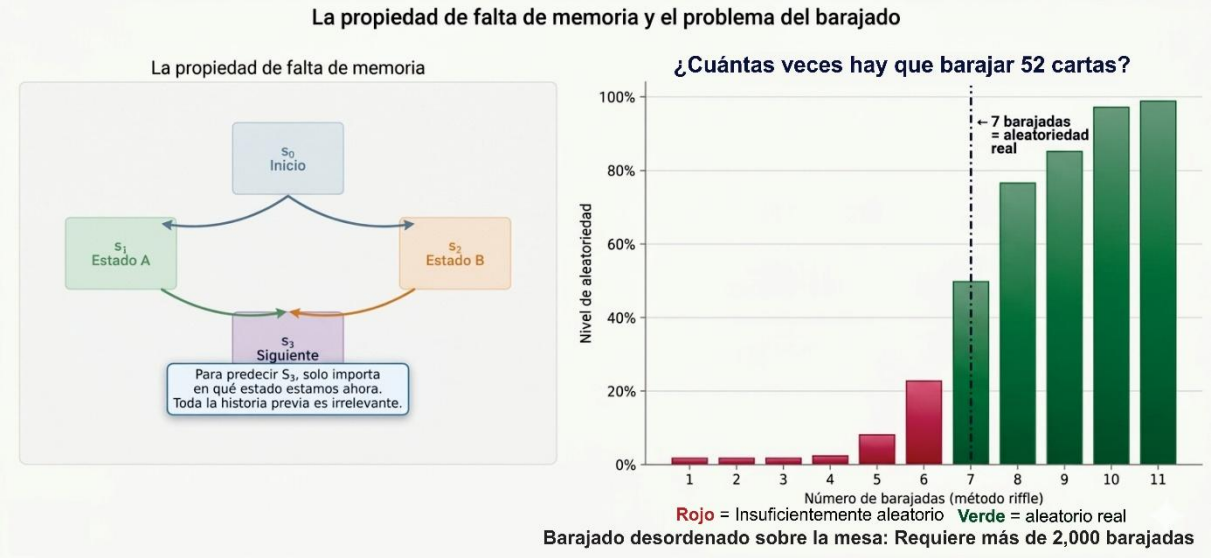


Figura 5

La propiedad de falta de memoria y el problema del barajado de cartas.

Nota. Panel izquierdo: representación esquemática de la propiedad de Markov, donde la predicción del estado siguiente depende únicamente del estado actual, ignorando toda la historia previa. Panel derecho: número de barajadas necesarias para alcanzar aleatoriedad real en un mazo de 52 cartas mediante el método riffle. Las barras rojas indican barajadas insuficientes; las verdes, mezcla estadísticamente aleatoria. Fuente: Adaptado de Bayer y Diaconis (1992).

X. Implicancias para la inteligencia artificial y el mundo actual

Comprender las cadenas de Markov no es solo un ejercicio de historia de las matemáticas. Es entender la arquitectura conceptual sobre la que descansan algunas de las tecnologías más influyentes del mundo actual. Cuando un modelo de lenguaje predice la siguiente palabra

de un mensaje, cuando el algoritmo de Google determina qué página merece el primer lugar en los resultados de búsqueda, o cuando un simulador de dinámica molecular modeliza el comportamiento de proteínas en la investigación farmacéutica, la estructura subyacente es siempre la misma: un sistema de estados con probabilidades de transición cuya distribución a largo plazo converge a un equilibrio.

Esta arquitectura tiene una consecuencia práctica para quienes trabajan con herramientas de inteligencia artificial. Los modelos de lenguaje no “saben” nada en el sentido en que lo sabe un experto humano. Son máquinas de predicción probabilística extraordinariamente sofisticadas, herederas directas del experimento que Markov realizó con un poema ruso hace más de un siglo. Producen la continuación estadísticamente más probable de una secuencia de texto, ponderada por el contexto disponible. Esa diferencia no los hace inútiles; los hace herramientas extraordinariamente poderosas en manos de quien comprende sus límites. Y comprender esos límites requiere, en última instancia, entender qué son realmente las cadenas de Markov.

XI. Conclusión

La historia de las cadenas de Markov es un recordatorio de que las ideas matemáticas más influyentes rara vez nacen de problemas prácticos. Nacen de disputas intelectuales, de la necesidad de demostrar que alguien está equivocado, de la curiosidad de un convaleciente sobre las probabilidades de ganar al solitario. Markov no pretendía inventar una herramienta para los físicos del Proyecto Manhattan ni para los ingenieros de Google del siglo XXI. Pretendía demostrar que un estadístico religioso confundía independencia estadística con libertad metafísica.

Y sin embargo, la estructura matemática que construyó para ganar esa discusión resultó ser uno de los descriptores más versátiles de los sistemas complejos que existen. Está en el núcleo de los motores de búsqueda, en los modelos de predicción climática, en los algoritmos de recomendación de contenido, en los simuladores de dinámica de mercados financieros y en los modelos de lenguaje que definen la vanguardia de la inteligencia artificial generativa actual.

Al final, hemos vuelto al principio: cultivar la capacidad de pensar. Inductiva, deductiva e intuitivamente. Eso nunca fue sustituible y no lo será ahora. Las cadenas de Markov, como toda gran idea matemática, son una herramienta que amplifica el pensamiento de quien las comprende, y una caja negra opaca para quien las usa sin entenderlas.

Referencias

Bayer, D., y Diaconis, P. (1992). Trailing the dovetail shuffle to its lair. Annals of Applied Probability, 2(2), 294-313. https://doi.org/10.1214/aoap/1177005705

Brin, S., y Page, L. (1998). The anatomy of a large-scale hypertextual web search engine. Computer Networks and ISDN Systems, 30(1-7), 107-117. https://doi.org/10.1016/S0169-7552(98)00110-X

Eckhardt, R. (1987). Stan Ulam, John von Neumann, and the Monte Carlo Method. Los Alamos Science, 15, 131-137.

Feller, W. (1968). An introduction to probability theory and its applications (3.ª ed., vol. 1). Wiley.

Hayes, B. (2013). First links in the Markov chain. American Scientist, 101(2), 92-97. https://doi.org/10.1511/2013.101.92

Page, L., Brin, S., Motwani, R., y Winograd, T. (1999). The PageRank citation ranking: Bringing order to the web. Stanford InfoLab Technical Report. http://ilpubs.stanford.edu:8090/422/

Sethna, J. P. (2006). Statistical mechanics: Entropy, order parameters, and complexity. Oxford University Press.

Shannon, C. E. (1948). A mathematical theory of communication. Bell System Technical Journal, 27(3), 379-423. https://doi.org/10.1002/j.1538-7305.1948.tb01338.x

Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, L., y Polosukhin, I. (2017). Attention is all you need. Advances in Neural Information Processing Systems, 30. https://arxiv.org/abs/1706.03762

Britannica. (2026). ENIAC. Encyclopaedia Britannica. https://www.britannica.com/technology/ENIAC

Metropolis, N., y Ulam, S. (1949). The Monte Carlo method. Journal of the American Statistical Association, 44(247), 335-341. https://doi.org/10.1080/01621459.1949.10483310